

Разработка неавторегрессионной seq2seq-архитектуры для генерации текста на основе прото-токенов.

1. Актуальность проблемы

Современные большие языковые модели (LLM) демонстрируют высокое качество генерации текста, однако практически все существующие архитектуры используют авторегрессионный механизм декодирования. При таком подходе каждый токен генерируется последовательно, что приводит к линейному росту вычислительных затрат относительно длины последовательности, и ограничивает скорость вывода, особенно при генерации длинных текстов.

В связи с этим активно развивается направление неавторегрессионной генерации, позволяющее формировать последовательность за существенно меньшее число шагов. Авторы работы “Exploring the Latent Capacity of LLMs for One-Step Text Generation” (<https://arxiv.org/abs/2505.21189>) показали, что замороженная LLM способна восстановить сотни токенов текста всего из двух обучаемых векторов - прото-токенов, поданных на вход вместо обычных эмбеддингов.

Однако ключевым остается вопрос о природе таких представлений: какую информацию они кодируют и насколько они пригодны для использования в качестве промежуточного состояния для создания новой seq2seq архитектуры генерации текста.

2. Цель исследования

Целью исследования является анализ внутренней структуры прото-токенов и разработка научных оснований для построения неавторегрессионных seq2seq-архитектур, использующих прото-токены как промежуточное представление между входной инструкцией и выходным текстом.

Работа разделена на два этапа:

- **Этап 1 (завершен):** анализ семантических, синтаксических и структурных свойств прото-токенов.
- **Этап 2 (в разработке):** проектирование и исследование архитектур одношаговой генерации текста на основе прото-токенов.

3. Методы исследования

Для проведения исследования разработан программный комплекс, обеспечивающий полный цикл экспериментов с прото-токенами.

В основе исследования лежит процедура оптимизации прото-токенов. Для каждого исследуемого текста формируется входная последовательность, в которой на первую позицию помещается прото-токен **e**, а остальные позиции заполняются копиями прото-токена **m**, где количество копий соответствует длине целевой последовательности - 1. После этого параметры большой языковой модели полностью замораживаются, а оптимизируются только два эмбединга прото-токенов. Оптимизация выполняется по функции потерь кросс-энтропии между исходным и реконструированным текстом, в результате чего для каждого предложения получается компактное непрерывное представление, позволяющее восстановить текст за один проход модели.

Для исследования семантических свойств прото-токенов для каждого исходного предложения генерировались две группы аугментаций: лексические преобразования с использованием библиотеки **Augmentex** и семантические преобразования в виде парафраз, сгенерированных моделью **Qwen3-8B**. Для каждого полученного текста независимо оптимизировались прото-токены, после чего анализировались расстояния между ними. Предполагалось, что если прото-токены кодируют семантическую информацию, то представления исходного предложения и его аугментированных версий будут располагаться близко в латентном пространстве.

Для исследования синтаксических свойств был разработан генератор предложений на основе контекстно-свободных грамматик, позволяющий получать тексты различных синтаксических типов (повествовательные, вопросительные, побудительные и др.). Для каждого предложения оптимизировались прото-токены, после чего анализировалось, располагаются ли представления предложений с одинаковой грамматической структурой близко друг к другу в латентном пространстве.

Помимо анализа семантики и синтаксиса исследовалась устойчивость прото-токенов к шумовым воздействиям и анализировались карты внимания трансформера, позволяющие определить вклад каждого прото-токена в процесс одношаговой реконструкции текста.

Отдельным направлением исследования стало формирование семантически организованного пространства прото-токенов. Для этого были реализованы два подхода регуляризации. В первом случае к функции потерь добавлялась якорная регуляризация, минимизирующая расстояние между прото-токенами и эмбедингами текстов, полученными внешней моделью эмбедреса (**Qwen3-Embedding-8B**). Во втором случае использовался подход **relation distillation**, при которой сохранялись не абсолютные координаты представлений, а относительные расстояния между ними. Это позволяло переносить структуру внешнего семантического пространства в пространство прото-токенов без жесткой привязки к конкретным векторам.

Второй этап исследования посвящен разработке неавторегрессионной seq2seq-архитектуры, использующей прото-токены в качестве промежуточного скрытого представления между входной инструкцией и выходным текстом. Предлагаемый подход предполагает обучение энкодера, который по входной инструкции предсказывает прото-токены, после чего замороженная большая языковая модель выполняет одношаговую реконструкцию ответа.

В рамках исследования предложены три способа построения такого энкодера.

Первый подход основан на использовании дискретного латентного пространства: прото-токены представляются как комбинация элементов обучаемых кодовых книг, а их выбор осуществляется с помощью механизма Gumbel-Softmax (как в работе [wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations](#)).

Второй подход использует общее латентное пространство вариационных автоэнкодеров (CADA-VAE), в котором инструкции и прото-токены отображаются в единое пространство представлений, что позволяет выполнять их согласование в процессе обучения (подробнее в [Generalized Zero- and Few-Shot Learning via Aligned Variational Autoencoders](#)).

Третий подход предполагает непосредственное предсказание непрерывных прото-токенов по входной инструкции с использованием контрастивных функций

потерь, объединяющей ошибку реконструкции текста и ошибку восстановления самих прото-токенов.

Все предложенные архитектуры используют замороженную большую языковую модель только на этапе декодирования, а их основное различие заключается в способе формирования промежуточного скрытого представления. В настоящее время разработаны концепции архитектур и их программная реализация, следующим этапом исследования является эффективное обучение моделей и их экспериментальное сравнение.

4. Научная новизна

Научная новизна работы заключается в исследовании свойств прото-токенов как фундамента для создания нового класса неавторегрессионных языковых моделей.

В работе впервые выполнено комплексное исследование свойств прото-токенов, кодируемой внутри их информации и предложены одношаговые seq2seq архитектуры генерации текста использующие прото-токены.

5. Основные результаты

В ходе исследования были получены следующие результаты:

- Разработан программный комплекс для экспериментального анализа прото-токенов.
- Установлено, что различные компоненты прото-токенов специализируются на разных типах информации: семантической и структурной.
- Выполнен анализ устойчивости представлений прото-токенов к шуму, и исследованы механизмы внимания модели во время одношаговой реконструкции текста.
- Предложен способ структуризации пространства прото-токенов.
- Предложены три новые seq2seq архитектуры генерации текста, использующих прото-токены.
- Подготовлена и представлена статья (<https://arxiv.org/abs/2602.18301>) на международной конференции AINL 2026.

6. Практическая значимость и перспективы

Полученные результаты расширяют понимание внутренних представлений больших языковых моделей и создают основу для разработки высокопроизводительных систем генерации текста нового поколения. Предложенные архитектуры потенциально позволяют отказаться от последовательного декодирования и существенно сократить время генерации ответов.

Результаты первого этапа исследования оформлены в виде препринта (<https://arxiv.org/abs/2602.18301>) и представлены на международной конференции AINL 2026. В дальнейшем планируется завершить экспериментальную проверку предложенных архитектур, выполнить их сравнительный анализ и разработать полноценную неавторегрессионную seq2seq-модель, использующую прото-токены в качестве промежуточного скрытого представления.