

## Построение неавторегрессионного Seq2Seq-пайплайна на основе скрытых возможностей LLM для одношаговой генерации

**Общая гипотеза:** подход на основе "прото-токенов" [1] позволяет построить неавторегрессионную модель генерации, которая не уступает по качеству авторегрессионным LLM, обладает значительно более высокой скоростью вывода, способностью оценивать собственную неопределенность и устойчивостью к распределительным сдвигам.

### План экспериментов

#### Фаза 1: Исследование природы сжатых представлений

**Цель:** Определить, какую лингвистическую информацию (синтаксис, семантика, лексика) кодируют прото-токены  $e$  и  $m$ .

##### Эксперименты:

- **синтаксис:** реконструкция текстов на синтетическом псевдоязыке [2];
- **семантика:** реконструкция списков фактов, определений, где синтаксис минимален;
- **как оценивать:** точность пословной реконструкции, анализ ошибок (служебные vs. смысловые слова), перплексия.

#### Фаза 2: Адаптация метода для построения инструкционной LLM

**Цель:** Настроить метод для эффективного сжатия и восстановления ответов в инструкционном датасете.

##### Эксперименты:

- **базовый подход:** обучение уникальных  $e$  и  $m$  для ответа (response) в каждом примере «эталонно размеченного» инструкционного датасета

типа `databricks/databricks-dolly-15k` на основе некоторой предобученной LLM, например, семейства Pythia [3];

- **абляционные исследования:**

- сравнение схем  $m_{\text{shared}}$  (один на все),  $m_{\text{per\_category}}$  (по категориям датасета Dolly) и  $m_{\text{per\_example}}$ .
- проверка гипотезы о "механистической" роли  $m$  (замена на фиксированный вектор).

- **масштабирование:** исследование зависимости качества реконструкции от размера модели-декодера (на семействе Pythia).

### Фаза 3: Создание и обучение энкодера для оценки $e$ , $m$ и $length$

**Цель:** Обучить модель, которая по инструкции (входному тексту) предсказывает оптимальные параметры  $e$  и  $m$  для генерации ответа (response) и длину этого ответа (в токенах)  $length$ .

#### Эксперименты:

- **архитектура:** выбор энкодера (например, RoBERTa), проекционных голов для  $e$ ,  $m$  и регрессионной головы для  $length$ .
- **функции потерь:**
  - для  $e$  и  $m$ : сравнение контрастивных функций потерь distance-based logistic loss [4], SigLIP [5] и других;
  - для  $length$ : функция потерь на основе минимизации отрицательного логарифмического правдоподобия для гауссовского распределения ошибок оценивания целевой переменной [6].
- **валидация:** Оценка конечного пайплайна (энкодер  $\rightarrow e, m, length \rightarrow$  декодер  $\rightarrow$  ответ) на качестве реконструкции Dolly-15k.

## Фаза 4: Всестороннее сравнение с авторегрессионными LLM

**Цель:** Доказать, что неавторегрессионный seq2seq-пайплайн конкурентоспособен.

### Эксперименты:

- **Качество:** Сравнение неавторегрессионного seq2seq-пайплайна с сопоставимыми по размеру авторегрессионными моделями (декодерными типа GPT и seq2seq типа FLAN-T5) на бенчмарках понимания языка (MMLU, MMLU-Pro, GSM8K и др.).
- **Устойчивость:** Построение F1-retention curve [7] для оценки устойчивости к сдвигам распределения.
- **Производительность:** замеры latency (время отправкой входного промпта и получением сгенерированного ответа) и throughput (количество генерируемых токенов в секунду) на различных длинах ответов в сравнении с авторегрессионным бейзлайном, а также бейзлайном на основе stable diffusion типа LLaDA [8].
- **Полезность оценки неопределенности:** Проверка, что высокая предсказанная неопределенность коррелирует с фактически низким качеством ответа, позволяя модели "воздерживаться" от ответа.

### Список литературы

1. *Gleb Mezentssev, Ivan Oseledets. Exploring the Latent Capacity of LLMs for One-Step Text Generation* // arXiv preprint arXiv:2505.21189. – 2025.
2. *Taisiya Gorbacheva, Ivan Bondarenko. Safe Pretraining of Deep Language Models in a Synthetic Pseudo-Language* // Dokl. Math. 108 (Suppl 2). – 2023.

3. *Stella Biderman, Hailey Schoelkopf et al.* **Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling** // Proceedings of the 40th International Conference on Machine Learning (ICML 2023). – 2023.
4. *Nam N. Vo, James Hays.* **Localizing and Orienting Street Views Using Overhead Imagery** // Proceedings of the 14th European Conference on Computer Vision (ECCV 2016). – 2016.
5. *Xiaohua Zhai, Lucas Beyer et al.* **Sigmoid Loss for Language Image Pre-Training** // Proceedings of the International Conference on Computer Vision (ICCV 2023). – 2023.
6. *D. A. Nix, A. S. Weigend.* **Estimating the mean and variance of the target probability distribution** // In IEEE International Conference on Neural Networks. – 1994.
7. *Andrey Malinin et al.* **Shifts: A Dataset of Real Distributional Shift Across Multiple Large-Scale Tasks** // Proceedings of the 35th Conference on Neural Information Processing Systems (NeurIPS 2021). – 2021.
8. *Fengqi Zhu, Rongzhen Wang et al.* **LLaDA 1.5: Variance-Reduced Preference Optimization for Large Language Diffusion Models** // arXiv preprint arXiv:2505.19223. – 2025.